SEMINÁRIO DE ARQUITETURA DE COMPUTADORES

Multiprocessors e Network Topologies

Sessões 6.7 e 6.8 — Computer Organization and Design RISC-V Edition

Enzo Nogueira Sarafim (ens2) • Gabriel Marins Zarour (gmz) • Kayque Tavares Marcelino da Costa (ktmc)

Sessão 6.7

Clusters e Warehouse-Scale Computers (WSC)

Clusters



Nodes Independentes

Processamento autônomo acoplado fracamente.

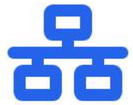
Ex: Beowulf Clusters.



COTS Hardware

Commercial Off-The-Shelf hardware.

Ex: Servidores x86 1U em racks.



Message Passing

Comunicação em rede, sem Shared Memory.

Ex: MPI (Message Passing Interface).

Virtual Machines (VMs) em Produção

Isolamento & Consolidação

Hypervisors abstraem o hardware físico subjacente, garantindo segurança.

Ex: VMware ESXi, KVM (Kernel-based VM).

Resource Pooling

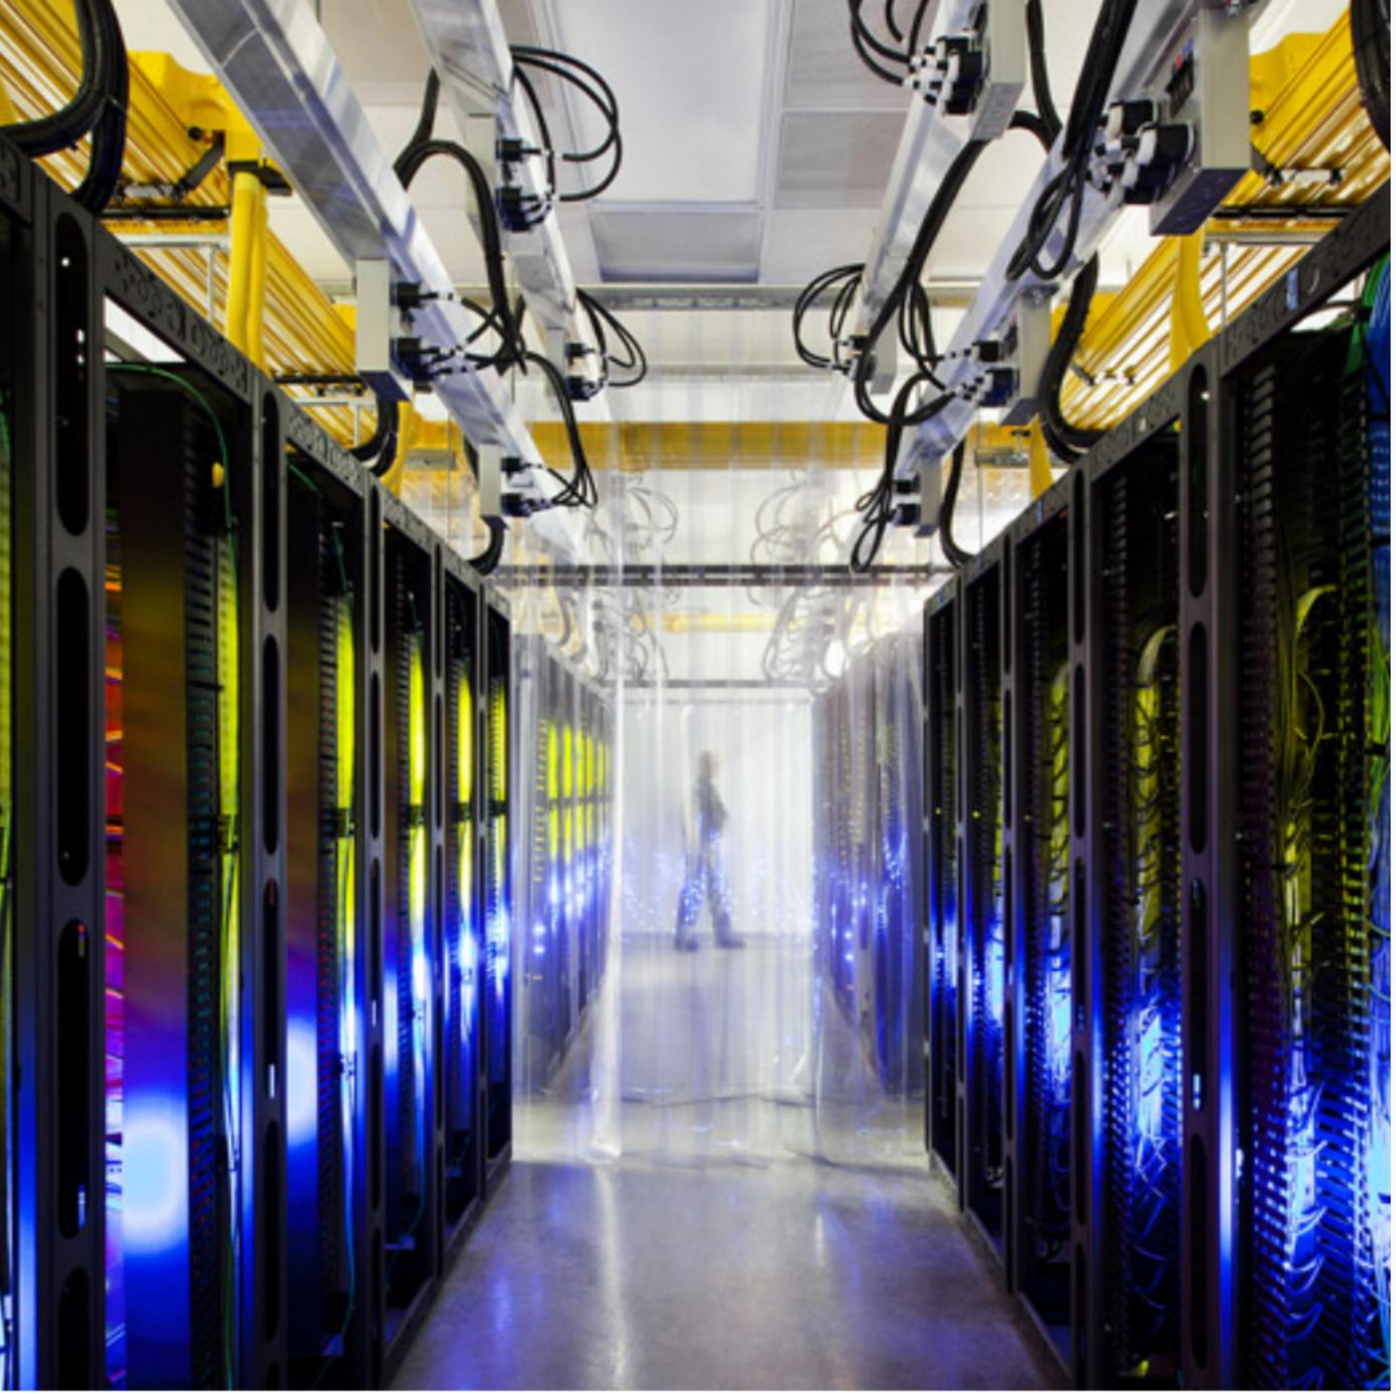
Alocação dinâmica e multi-tenancy de CPU, RAM e I/O.

Ex: Amazon EC2 Instances, Clusters Kubernetes.



Clusterização de VMs

Uso de Live Migration (migração a quente) entre diferentes Nodes de um Datacenter para balanceamento sem downtime.



INFRAESTRUTURA WSC

Warehouse-Scale Computers

Dezenas de milhares de servidores orquestrados como um supercomputador único.

Ex: Google Datacenters (Oregon), AWS Availability Zones.

Hierarquia de Storage em WSCs

Direct Attached Storage (DAS)

Discos conectados fisicamente ao Node. Baixíssima latência, ideal para local cache.

Ex: SSDs NVMe locais em blades.

SAN & NAS

Storage Area Network / Network Attached Storage. Compartilhamento em rede dedicada.

Ex: Arrays com Fibre Channel ou iSCSI.

Distributed File Systems

Abstração por software via rede TCP/IP, criando redundância massiva em discos baratos.

Ex: Google File System (GFS), Hadoop HDFS.

Desafios Operacionais em WSCs

- **Power & Cooling:** Limitado pela PUE (Power Usage Effectiveness).
  Ex: PUE Ideal = 1.0. Meta/Google mantêm entre 1.09 a 1.20.
- **Reliability:** Escala massiva resulta em falhas diárias de discos (MTTF vs MTTR).
  Ex: Discos pifam. O MTTR (Mean Time To Repair) dita o custo.
- **Software Fault Tolerance:** Assumir que o hardware vai falhar.
  Ex: MapReduce reatribuindo jobs automaticamente para Nodes saudáveis.

Perspectiva Financeira: TCO em WSCs

CAPEX (Despesas de Capital)

Maior fatia do custo de aquisição inicial.

Servidores, infraestrutura de rede e construção do galpão.

~45-60%

Do custo total (estimativa em WSCs).

OPEX (Despesas Operacionais)

Energia elétrica e refrigeração contínuas.

Conta de energia ultrapassa valor do hardware em 3 anos.

PUE Baixo

Fator crucial para redução do custo a longo prazo.

Sessão 6.8

Network Topologies em Multiprocessors

Métricas Fundamentais de Rede

B/W

Bandwidth

Capacidade de transferência.

Ex: PCIe 5.0 (64 GB/s).

Lat

Latency

Atraso por saltos de roteamento.

Ex: InfiniBand NDR (< 1 µs).

B/C

Bisection Bandwidth

Corte no pior cenário da rede.

Ex: Limite em All-to-All broadcast.

Ring & Mesh

Ring: Roteamento vizinho estrito.

Ex: Barramento interno de multicore (Intel Xeon).

Mesh: Malha 2D de interconexão em grade.

Ex: Google TPU v4 (Chips AI) e processadores Tilera.



Alta Escalabilidade

Torus (3D Torus)

- Mesh com fechamentos circulares nas bordas.
- Reduz a maior distância do diâmetro da rede.

Ex: Supercomputador IBM Blue Gene/L, Tofu em Fugaku.

Hypercube

- Conexões crescem em dimensões log(N).
- Bisection Bandwidth extrema, fiação complexa.

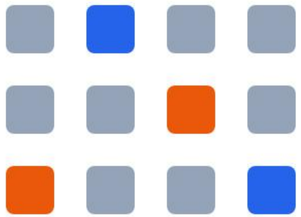
Ex: Máquinas maciçamente paralelas (Connection Machine).

Crossbar & Multistage Networks

Crossbar Switch

Matriz não-bloqueante (Non-blocking). Qualquer Node origem comunica com destino direto.

Ex: Roteadores de núcleo em Datacenters Cisco/Juniper.



Multistage (Omega Network)

Redes em múltiplos estágios com chaves 2×2.
Escalonamento logarítmico para reduzir custo $O(N^2)$.

Ex: Interconexões de servidores SMP (Sun Fire, IBM pSeries).

ECONOMIA DAS REDES

O Custo Oculto da Topologia

$O(N^2)$

Crossbar Puro

Financeiramente insustentável para grandes WSCs.

Custo de fabricação do hardware explode rapidamente.

$O(N \log N)$

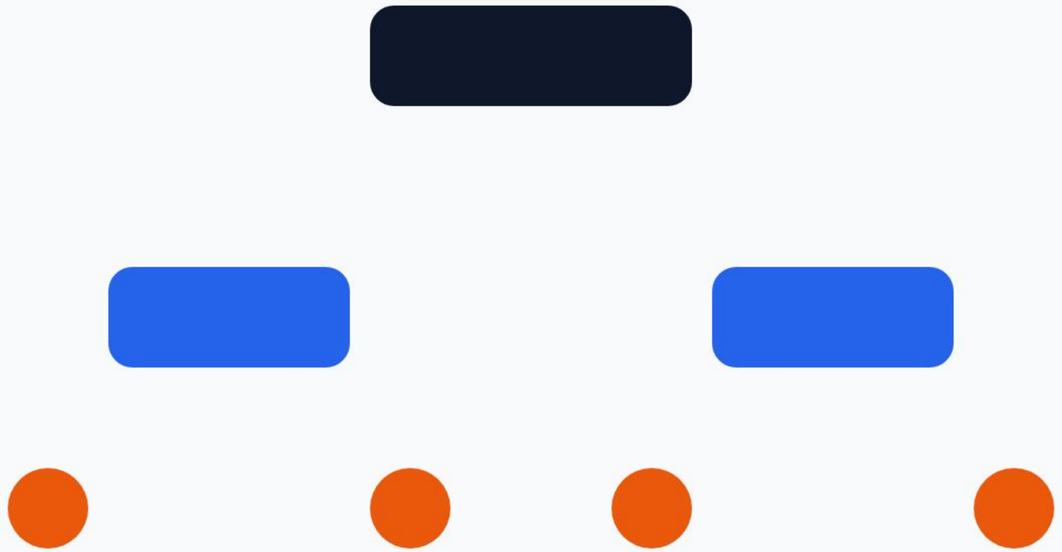
Multiestágio

Reduz drasticamente o CAPEX de rede.

Substitui chaves gigantes por pequenas conexões.

Cabeamento e switches representam até 15% do custo total de um WSC.

Fat-Tree Topology



Bandwidth dos links engrossa conforme sobem à raiz, eliminando gargalos no Core.

Ex: Switches Nvidia/Mellanox InfiniBand em clusters de Inteligência Artificial modernos.

Dúvidas?

Centro de Informática — UFPE

Enzo Nogueira Sarafim (ens2) • Gabriel Marins Zarour (gmz) • Kayque Tavares Marcelino da Costa (ktmc)

Image Sources



https://storage.googleapis.com/gweb-cloudblog-publish/images/Screenshot_2025-03-12_at_5.46.38PM.max-1700×1700.png

Source: cloud.google.com



https://images.stockcake.com/public/2/4/1/241508df-3f0d-4fe0-a963-0d3270e3acd3_large/glowing-data-pathways-stockcake.jpg

Source: stockcake.com